



AGH

**AKADEMIA GÓRNICZO-HUTNICZA IM. STANISŁAWA STASZICA W
KRAKOWIE**

**WYDZIAŁ ELEKTROTECHNIKI, AUTOMATYKI,
INFORMATYKI I INŻYNIERII BIOMEDYCZNEJ**

KATEDRA INFORMATYKI STOSOWANEJ

Praca dyplomowa inżynierska

Obliczenia rozproszone w języku Haskell
Distributing tasks with Haskell

Autor:	<i>Konrad Lewandowski</i>
Kierunek studiów:	<i>Informatyka</i>
Opiekun pracy:	<i>dr inż. Piotr Matyasik</i>

Kraków, 2017

Uprzedzony o odpowiedzialności karnej na podstawie art. 115 ust. 1 i 2 ustawy z dnia 4 lutego 1994 r. o prawie autorskim i prawach pokrewnych (t.j. Dz.U. z 2006 r. Nr 90, poz. 631 z późn. zm.): „Kto przywłaszcza sobie autorstwo albo wprowadza w błąd co do autorstwa całości lub części cudzego utworu albo artystycznego wykonania, podlega grzywnie, karze ograniczenia wolności albo pozbawienia wolności do lat 3. Tej samej karze podlega, kto rozpowszechnia bez podania nazwiska lub pseudonimu twórcy cudzy utwór w wersji oryginalnej albo w postaci opracowania, artystycznego wykonania albo publicznie zniekształca taki utwór; artystyczne wykonanie, fonogram, wideogram lub nadanie.”, a także uprzedzony o odpowiedzialności dyscyplinarnej na podstawie art. 211 ust. 1 ustawy z dnia 27 lipca 2005 r. Prawo o szkolnictwie wyższym (t.j. Dz. U. z 2012 r. poz. 572, z późn. zm.): „Za naruszenie przepisów obowiązujących w uczelni oraz za czyny uchybiające godności studenta student ponosi odpowiedzialność dyscyplinarną przed komisją dyscyplinarną albo przed sądem koleżeńskim samorządu studenckiego, zwanym dalej «sądem koleżeńskim».”, oświadczam, że niniejszą pracę dyplomową wykonałem(-am) osobiście i samodzielnie i że nie korzystałem(-am) ze źródeł innych niż wymienione w pracy.

*Serdecznie dziękuję ...tu ciąg dalszych
podziękowań np. dla promotora, żony, są-
siada itp.*

Spis treści

1. Wprowadzenie	7
1.1. Cel i założenia pracy	7
1.2. Istniejące rozwiązania	7
1.2.1. Celery	7
1.2.2. Resque	7
1.2.3. Cloud Haskell	8
1.3. Zawartość pracy	8
2. Implementacja rozpraszania zadań	9
2.1. Zarządzanie zasobami	9
2.2. Środowisko funkcji	11
2.3. Odczyt konfiguracji z pliku	13
2.4. Obsługa zadań	13

Listingi kodu

2.1 Łączenie z RabbitMQ	9
2.2 Regionalizacja zasobów	9
2.3 Problem funkcji asynchronicznych	10
2.4 Typ reader	11
2.5 Transformator typu Reader	12
2.6 Schemat obsługi zadania	13
2.7 Problem typu zadania zdefiniowanego egzystencjalnie	14

1. Wprowadzenie

W czasach kiedy przewidywania Gordona Moore'a dotyczące dalszego wzrostu mocy obliczeniowej pojedynczych komputerów przestają się sprawdzać, coraz częściej wykorzystujemy metody wykonywania programów oparte na jednoczesnym przetwarzaniu rozproszonym na wielu połączonych ze sobą maszynach.

Pomimo pozornej prostoty takiego rozwiązania istnieje bardzo niewiele narzędzi ułatwiających programowanie w modelu rozproszonym.

1.1. Cel i założenia pracy

Celem poniższej pracy jest implementacja w języku Haskell podstawowej biblioteki do rozpraszania zadań na wielu komputerach z wykorzystaniem brokera RabbitMQ, umożliwiającą zlecanie zadań do wykonania, przerywanie zadań będących w trakcie wykonywania, raportowanie na bieżąco postępów wykonania, przesyłania wyników oraz wprowadzanie zależności pomiędzy zadaniami.

1.2. Istniejące rozwiązania

Poniższa lista zawiera skrócony opis istniejących bibliotek programistycznych, służących do obliczeń rozproszonych:

1.2.1. Celery

Celery jest asynchroniczną kolejką zadań opartą o rozproszone komunikaty przesyłane między komputerami, napisaną w języku Python. Działa w czasie rzeczywistym, jednak umożliwia również szeregowanie zadań. Interfejs programistyczny pozwala na zlecanie zadań zarówno w sposób synchroniczny jak i asynchroniczny, oraz przesyłanie wyników. Wspiera wiele brokerów wiadomości (np. RabbitMQ, Redis, MongoDB).

1.2.2. Resque

Resque jest biblioteką języka Ruby, wykorzystującą bazę Redis w charakterze brokera wiadomości. Umożliwia asynchroniczne zlecanie powtarzalnych zadań na innych komputerach.

Biblioteka ta jest często używana przez programistów serwisów internetowych do wykonywania długotrwałych operacji (np. generowanie miniaturek zdjęć, rozsyłanie newslettera e-mail, tworzenie raportów, etc...)

1.2.3. Cloud Haskell

Cloud Haskell to biblioteka języka Haskell, udostępniająca warstwę transportową do komunikacji między węzłami, mechanizm serializacji domknięć pozwalający na zdalne uruchamianie procesów oraz API do programowania rozproszonego.

1.3. Zawartość pracy

W rozdziale 1 cośtamcośtam...

2. Implementacja rozpraszania zadań

Poniższy rozdział został poświęcony różnym aspektom implementacyjnym.

2.1. Zarządzanie zasobami

Protokół AMQP operuje na zależnych od siebie zasobach, którymi należy w poprawny sposób zarządzać. Postawowy przykład z dokumentacji biblioteki AMQP w przypadku wystąpienia wyjątku nie gwarantuje zwolnienia zasobu, a kolejność wykonywania finalizatorów ze względu na leniwą ewaluację jest determinowana wyłącznie wyzwoleniem mechanizmu odśmiecania.

```
1 main = do
2   conn <- openConnection "127.0.0.1" "/" "guest" "guest"
3   ...
4   closeConnection conn
```

Listing 2.1. Łączenie z RabbitMQ

Jednym z istniejących rozwiązań tego problemu jest biblioteka `io-region`[1], umożliwiająca podział kodu na regiony odpowiedzialne za poszczególne zasoby oraz przenoszenie tych odpowiedzialności pomiędzy regionami

```
1 ...
2 region $ \r -> do
3   connection <- alloc_ r (AMQP.openConnection host vhost username password)
4   AMQP.closeConnection
5   -- po opuszczeniu regionu następuje zwolnienie zasobów
6   ...
```

Listing 2.2. Regionalizacja zasobów

Rejestrowanie zasobów w obrębie odpowiednich regionów rozwiązuje również problem asynchronicznych wywołań zwrotnych, służących do obsługi nadchodzących komunikatów z brokera. Dla porównania, niewłaściwe rozwiązanie oparte o mechanizm `bracket` powoduje przedwczesne zamknięcie zasobu nadal wykorzystywanego przez funkcję uruchamianą asynchronicznie.

```
1  ...
2  bracket openConnection closeConnection $ \connection ->
3      bracket (openChannel connection) closeChannel $ \channel1 ->
4          consumeMsgs channel1 queue callback -- wywołanie asynchroniczne
5          -- nieporządane zamknięcie kanału
6          -- otwarcie drugiego kanału
7      bracket (openChannel connection) closeChannel $ \channel2 ->
8          consumeMsgs channel2 queue callback -- wywołanie asynchroniczne
9          -- nieporządane zamknięcie kanału
10     _ <- getLine -- oczekiwanie
11     -- zamknięcie połączenia
12
13     ...
14     region $ \r -> do
15         connection <- alloc_ r openConnection closeConnection
16         channel1 <- alloc_ r (openChannel connection) closeChannel
17         consumeMsgs channel1 queue callback
18         channel2 <- alloc_ r (openChannel connection) closeChannel
19         consumeMsgs channel2 queue callback
20
21     _ <- getLine -- oczekiwanie
22     -- zwolnienie zasobów w poprawnej kolejności
```

Listing 2.3. Problem funkcji asynchronicznych

2.2. Środowisko funkcji

Większość funkcji związanych z protokołem AMQP wymaga do działania przekazania pewnego zasobu (jak na przykład obiekt `Connection` lub `Channel`). Robienie tego za każdym razem `explicite` prowadzi do zmniejszenia czytelności kodu. Idiomatycznym dla języka Haskell rozwiązaniem jest zastosowanie typu `Reader` [2]:

```
1 newtype Reader e a = Reader { runReader :: e -> a }
2
3 instance Functor (Reader e) where
4   fmap f r = Reader $ \e -> f (runReader r e)
5
6 instance Applicative (Reader e) where
7   pure a    = Reader $ \e -> a
8   ra <*> rb = Reader $ \e -> (runReader ra e) (runReader rb e)
9
10 instance Monad (Reader e) where
11   (Reader r) >>= f = Reader $ \e -> runReader (f (r e)) e
12
13 ask :: Reader a a
14 ask = Reader id
```

Listing 2.4. Typ reader

Typ `Reader` opakowuje funkcję przyjmującą jako argument środowisko jej wykonania i zwracającą pewien wynik obliczeń wykorzystujących to środowisko. Przykładowo dla:

```
1 testReader :: Reader Bool String
2 testReader = Reader $ \flag -> if flag then "Włącz" else "Wyłącz"
3
4 runReader testReader True == "Włącz"
```

Jednak istotą działania `Reader`'a jest jego monadyczny interfejs umożliwiający zapisanie funkcji `testReader` jako:

```
1 testReader :: Reader Bool String
2 testReader = do
3   flag <- ask
4   return $ if flag then "Włącz" else "Wyłącz"
```

Dzięki temu unikamy przekazywania tego samego środowiska za każdym razem jako argumentu funkcji, co jest szczególnie istotne w przypadku kiedy jest to wiele funkcji.

Niestety funkcjonalność samej monady `Reader reader` nie jest wystarczająca ze względu na mnogość operacji wykorzystujących operacje wejścia-wyjścia, więc wymagających typu `IO` do działania. Pomocne tutaj okazują się transformatory monad (ang. *Monad transformers*[3]):

```

1 newtype ReaderT e m a = ReaderT { runReaderT :: e -> m a }
2
3 instance Functor m => Functor (ReaderT e m) where
4     fmap f r = ReaderT $ \e -> fmap f (runReaderT r e)
5
6 instance Applicative m => Applicative (ReaderT e m) where
7     pure a    = ReaderT $ \e -> pure a
8     ra <*> rb = ReaderT $ \e -> (runReaderT ra e) <*> (runReaderT rb e)
9
10 instance Monad m => Monad (ReaderT e m) where
11     r >>= f = ReaderT $ \e -> do
12         a <- runReaderT r e
13         runReaderT (f a) e
14
15 ask :: Monad m => ReaderT a m a
16 ask = ReaderT return
17
18 lift :: m a -> ReaderT e m a
19 lift m = ReaderT (const m)

```

Listing 2.5. Transformator typu Reader

Dzięki funkcji `lift` możemy niejako „podciągać” operacje wykonane w ramach innej monady do typu `ReaderT`:

```

1 testReader :: ReaderT Bool IO String
2 testReader = do
3     flag <- ask
4     lift $ if flag then putStrLn "Włącz"
5             else putStrLn "Wyłącz"
6     return "Wynik"
7
8 > runReaderT testReader True
9 Włącz

```

2.3. Odczyt konfiguracji z pliku

Biblioteka `configurator[Config]` TODO

2.4. Obsługa zadań

Mechanizm uruchamiania konkretnego zadania sprowadza się do odczytu odpowiedniej funkcji z tablicy mieszającej zawierającej wszystkie obsługiwane przez węzeł zadania na podstawie klucza będącego wybraną przez programistę nazwą zadania, a następnie uruchomienie (po odpowiednim sparametryzowaniu) tej funkcji wewnątrz oddzielnego wątku. Ogólny schemat wygląda następująco:

```

1 newtype Task = Task { runTask :: ByteString -> IO ByteString }
2
3 registeredTasks :: HashMap Text Task
4 registeredTasks = fromList [ ("name1", function1)
5                             , ("name2", function2)
6                             , ("name3", function3) ]
7 ...
8
9 handleTask (msg, env) = do
10   let Just taskName = AMQP.msgType msg
11   let taskArgs = AMQP.msgBody msg
12
13   forkIO $
14     result <- runTask (registeredTasks ! taskName) taskArgs
15     ...
16
17   AMQP.ackEnv env

```

Listing 2.6. Schemat obsługi zadania

Nieprzypadkowo typ `Task` to opakowana, monomorficzna funkcja przetwarzająca ciągi bajtów. Gdyby pokusić się o przeniesienie odpowiedzialności za deserializację argumentów i serializację wyników obliczeń, typ ten przyjąłby pozornie „bezpieczniejszą” formę egzystencjalną:

$$\forall_{a,b}(\text{Serializable } a, \text{Serializable } b) \Rightarrow a \rightarrow b$$

jednak w takiej sytuacji kompilator nie może ustalić typów polimorficznych a, b w kontekście fragmentu kodu obliczającego wartość:

```

1 {-# LANGUAGE ExistentialQuantification #-}
2 {-# LANGUAGE RankNTypes                #-}
3 module Test where
4
5 import Data.Store
6 import Data.Text
7 import Data.ByteString
8 import Data.HashMap.Strict
9
10 newtype Task = Task { runTask :: forall a b . (Store a, Store b)
11                      => a -> IO b }
12
13 registeredTasks :: HashMap Text Task
14 registeredTasks = ...
15
16 runTaskByName :: Text -> ByteString -> IO ByteString
17 runTaskByName taskName encodedArg = do
18   arg <- decodeIO encodedArg
19   result <- runTask (registeredTasks ! taskName) arg
20   -- Błąd sprawdzania jednoznaczności typów
21   return $ encode result

```

Listing 2.7. Problem typu zadania zdefiniowanego egzystencjalnie

Błąd ten jest analogiczny do przedstawionego poniżej bardziej podstawowego przykładu i wychwytyje go mechanizm sprawdzania jednoznaczności instancjonowanych typów:

```

1 show (read "5" :: Int)           => "5"
2 show (read "5" :: Double)       => "5.0"
3 show (read "5") => Ambiguous type variable 'a2' arising from a use of 'read'
4                             prevents the constraint '(Read a2)' from being solved.

```

Inferencja typu dla trzeciego wyrażenia przebiega w systemie Hindleya-Milnera[4] rozszerzonym o klasy typów[5] następująco:

$$\frac{\frac{\text{show} : \forall \alpha. (\text{Show } \alpha). \alpha \rightarrow \text{String} \in \Gamma}{\Gamma \vdash \text{show} : \forall \alpha. (\text{Show } \alpha). \alpha \rightarrow \text{String}} [\text{Var}]}{\frac{\frac{\frac{\langle 5 \rangle : \text{String} \in \Gamma}{\Gamma \vdash \langle 5 \rangle : \text{String}} [\text{Var}]}{\text{read } \langle 5 \rangle : \forall \alpha. (\text{Read } \alpha). \text{String} \rightarrow \alpha} [\text{App}]}{\text{read } \langle 5 \rangle : \forall \alpha. (\text{Read } \alpha). \alpha} [\text{Comb}]}{\text{show}(\text{read } \langle 5 \rangle) : \forall \alpha. (\text{Read } \alpha, \text{Show } \alpha). \text{String}} [\text{Comb}]$$

Rys. 2.1. Inferencja niejednoznacznego typu

Wynikowy typ zawiera restrykcje odnoszące się do zmiennej α niewystępującej poza kontekstem, więc wyrażenie takie nie posiada prawidłowego typu[6].

Bibliografia

- [1] Yuras Shumovich. *The io-region package*. 2015.
URL: <https://hackage.haskell.org/package/io-region>.
- [2] Mark P. Jones.
„Functional Programming with Overloading and Higher-Order Polymorphism”.
W: *Advanced Functional Programming, First International Spring School on Advanced Functional Programming Techniques-Tutorial Text*.
London, UK, UK: Springer-Verlag, 1995, s. 97–136. ISBN: 3-540-59451-5.
- [3] Sheng Liang, Paul Hudak i Mark Jones.
„Monad Transformers and Modular Interpreters”. W: *Proceedings of the 22Nd ACM SIGPLAN-SIGACT Symposium on Principles of Programming Languages*. POPL '95.
San Francisco, California, USA: ACM, 1995, s. 333–343. ISBN: 0-89791-692-1.
DOI: 10.1145/199448.199528.
- [4] Luis Damas i Robin Milner. „Principal Type-schemes for Functional Programs”.
W: *Proceedings of the 9th ACM SIGPLAN-SIGACT Symposium on Principles of Programming Languages*. POPL '82. Albuquerque, New Mexico: ACM, 1982,
s. 207–212. ISBN: 0-89791-065-6. DOI: 10.1145/582153.582176.
- [5] P. Wadler i S. Blott. „How to Make Ad-hoc Polymorphism Less Ad Hoc”.
W: *Proceedings of the 16th ACM SIGPLAN-SIGACT Symposium on Principles of Programming Languages*. POPL '89. Austin, Texas, USA: ACM, 1989, s. 60–76.
ISBN: 0-89791-294-2. DOI: 10.1145/75277.75283.
- [6] Simon Marlow. „Haskell 2010 Language Report”. W: (2010).